

DNT Günü - Bioinformatika - Genom Məlumatlarının (Big Data) Analizi və Klinik İnterpretasiyası

**Süleyman Hacızadə, Biologiya, 4-cü kurs
Molekulyar Biologiya İnstitutu, DNT Günü - 2026**

Problem Nədir?

1 insan genomu $\approx$ 3 milyard baza cütü

NGS $\rightarrow$ milyonlarla read


Data var, amma:

Bioloji məna yoxdur

Klinik qərar yoxdur

Bioinformatika bu rəqəmləri klinik qərara çevirir

Bu İşdə Nə Etdik?



Analiz Pipeline

FASTQ (EBI/NCBI)



QC (FastQC or MultiQC)



Alignment (HISAT2)



Counting (FeatureCounts)



DESeq2 (DESeq2) (R)



Pathway (REACTOME, DAVID
Bioinformatics)



ML (RandomForest)



Klinik interpretasiya

```
bash
```

```
# EBI-dən real xəstə datası yükləndi
```

```
wget ftp://ftp.sra.ebi.ac.uk/.../SRR1313090_1.fastq.gz
```

```
wget ftp://ftp.sra.ebi.ac.uk/.../SRR1313091_1.fastq.gz
```

```
# ... 20 nümunə
```

Data Haradan Gəldi?

NCBI SRA / EBI bazası

Real SRR ID-lər

10 Tumor + 10 Normal

Bu data hər kəs tərəfindən yoxlana bilər

Bash:

```
wget
```

```
ftp://ftp.sra.ebi.ac.uk/.../SRR1313090.fastq.gz
```

```
ls /bioinformatics/Github/Bioinformatics-  
analysis/module_4_tnbc_paper/scripts/
```

FASTQ

Nədir?

4 sətirlik struktur:

ID

Nukleotid ardıcılığı

Separator

Keyfiyyət skoru

Raw data = yalnız rəqəm

```
@SRR1313090.1 ← Read ID (xəstə + oxunuş nömrəsi)
ATCGTACGATCGATCGATCGTAGCTAGCTAGC ← Nukleotid ardıcılığı
+ ← Separator
IIIIIIIIIIII9IIIIIIIIIIIIIIIIIIII ← Phred33 keyfiyyət skoru
```

Keyfiyyət skoru izahı:

Simvol	Phred	Dəqiqlik
I	40	99.99%
9	24	99.6%
!	0	0%

Keyfiyyət Kontrolu

Tool: FastQC

Məqsəd:

Base quality

GC content

Adapter contamination

Bash:

fastqc *.fastq.gz

multiqc .

Real kod (`run_qc.sh` -dan):

```
bash
```

```
#!/bin/bash
# 20 TNBC Human Sample – eyni anda 20 thread ilə
fastqc -t 20 -o fastqc_out/ *.fastq.gz

# Bütün 20 xəstənin raportunu bir yerdə birləşdir
multiqc . -n raw_multiqc_report.html
```

FastQC nə yoxlayır:

- Per base quality (hər mövqedə keyfiyyət)
- GC content (G+C faizi)
- Adapter contamination (xarici qatışıq)
- Sequence duplication (təkrarlama)

Vizual: FastQC `Per Base Quality` qrafiki — yaşıl zona keyfiyyətli, sarı/qırmızı problemli

Data Təmizlənməsi

Tool: Trimmomatic

Nə edir:

Aşağı keyfiyyətli hissələri
kəsir

Qısa read-ləri çıxarır

Garbage in → garbage out

Bash:

SLIDINGWINDOW:4:20

MINLEN:36

Real kod (`run_trimmomatic.sh` -dan):

```
bash
```

```
# Hər nümunə üçün:
```

```
trimmomatic SE -threads 2 -phred33 \  
  sample.fastq.gz \  
  trimmed/sample_trimmed.fastq.gz \  
  ILLUMINACLIP:adapters.fa:2:30:10 \  
  SLIDINGWINDOW:4:20 \   ← 4 bazalıq pəncərədə min keyfiyyət 20  
  MINLEN:36              ← 36 bazadan qısa read-ləri sil
```

```
# GNU Parallel ilə 10 nümunəni eyni anda işlət
```

```
ls *.fastq.gz | parallel -j 10 trim_file {}
```

Trimmomatic nə edir:

- `ILLUMINACLIP` → Adapter ardıcılıqlarını kəsir
- `SLIDINGWINDOW:4:20` → Keyfiyyəti aşağı düşən yeri kəsir
- `MINLEN:36` → Çox qısa read-ləri atar

Referens Genomla Hizalanma

Tool: HISAT2

Referens: hg38

Nəticə: BAM file

Bash:

hisat2 | samtools sort

Real kod (`run_hisat2.sh` -dan):

```
bash

# HISAT2 → hg38 referens genomuna hizala
# SAMtools → BAM-a çevir və çeşidlə
hisat2 -p 2 \
    -x /bioinformatics/module_2/references/hg38/genome \
    -U sample_trimmed.fastq.gz \
    2> sample_align.log \
| samtools view -bS - \
| samtools sort -o sample.bam

# BAM indeksləmə (sürətli axtarış üçün)
samtools index sample.bam
```

İzah:

- **hg38** = insan referens genomu (6 GB)
- **BAM** = Binary Alignment Map (sıxılmış format)
- Hər read genomda **harada** olduğu müəyyən edilir
- 3 paralel iş: `3 × 6GB RAM = 18GB` (optimal)

BAM Faylı

Binary alignment format
Hər read-in genomdakı
mövqeyi
Index → sürətli axtarış
Bioloji məna burada
yaranmağa başlayır

- **Binary Alignment Map** — sıxılmış ikili format
- Hər read üçün saxlanılan məlumat:
 - Genomdakı mövqe (chromosome, position)
 - Hizalanma keyfiyyəti (MAPQ)
 - CIGAR string (match/mismatch/indel)
- `.bai` indeks faylı → millisaniyədə istənilən bölgəyə atla

Vizual izah:

```
Read:  ATCGATCG
      ||| |||
hg38:  ATCGATCG ← chr1: pozisiya 1,234,567
```

Nəticə:

- 20 xəstə × ~25M read = **~500 milyon hizalanma**
- Hamısı BAM formatında saxlanıldı

Gen Ekspressiyasının Sayılması

Tool: FeatureCounts

Input: BAM

Output: Gene count
matrix

Bash:

featureCounts -a gtf -o
counts.txt

Real kod (`run_featurecounts.sh` -dan):

bash

```
# GTF annotasiya ilə 20 BAM faylındakı genləri say
featureCounts \
  -T 15 \                               ← 15 nüvə (sürət)
  -a gencode.v44.annotation.gtf \       ← gen annotasiyası
  -o temp_counts.txt \
  -t exon \                             ← exon səviyyəsində say
  -g gene_name \                       ← rəsmi gen adları
  alignment/*.bam                      ← 20 xəstə

# Matrisi CSV-ə çevir: gen_adı + 20 sütun (xəstə)
cat temp_counts.txt | sed '1d' \
  | cut -f 1,7-26 \
  | tr '\t' ',' > tnbc_gene_counts.csv
```

Nəticə:

- `tnbc_gene_counts.csv` = ~20,000 gen × 20 xəstə
- Bu — **Big Data** başlanğıcıdır


Nəticə Data

~20,000 gen

20 xəstə

Matrix format


Big Data başlanğıcı



PCA Plot – TNBC and Normal

Diferensial Ekspressiya

Tool: DESeq2
Model:
Negative binomial
Məqsəd:
Tumor vs Normal



Volcano Plot – TNBC and Normal


Diferensial Ekspressiya Analizi

log2FoldChange
adjusted p-value

R dili:

```
dds <- DESeq(dds)
```

```
res <- results(dds)
```




Top 50 DEG Heatmap

Nəticə Vizuallaşdırma

Qırmızı: up-regulated

Mavi: down-regulated


Xərçəngin molekulyar
portreti




Go Pathway - DotPlot

Bioloji Mexanizm


Tool: clusterProfiler
GO Biological Process



KEGG Pathway - DotPlot




TME Deconvolution Barplot



Immune Landscape Heatmap

Bioloji Mexanizmin
Əsas Tapıntıları

Cell cycle regulation
DNA repair
Immune response
Bu TNBC-nin əsas mexanizmidir



Random Forest ROC Curve – AUC = 0.97

AI Modeli

Random Forest

20 gen → feature

R dili:

```
randomForest(ntree=500)
```

Model Performansı


AUC = 0.97 (yüksək)

Yüksək dəqiqlik

Diagnoz avtomatlaşdırıla
bilər

Random Forest: Top 20 Predictor Genes (TNBC vs N

PDZRN4
NQO1.DT
H1.5
GFAP
ENSG00000260466
ENSG00000286836
SLC7A5
LINC02253
H3C8
PSAT1
GPR158
PPM1E
LEP
MDGA2
LRP8
CXCL13
ELFN2
ABCA12
ALB
NTNG1



ML Variable Importance – Top 20 Genes

Final Klinik Nəticə

Raw data → analiz


Analiz → biologiya

Biologiya → klinik qərar

Bioinformatika = qərar dəstəyi sistemi

Systems Biology: TNBC Hub-Gene Co-expression Network

Node size/color explicitly indicates the Master Regulator status (Hub Centrality).



Systems Biology Hub-Gene Network



Diqqətiniz üçün təşəkkürlər

Mənimlə əlaqə üçün məni sosial və iş mediasından izləyə
və əməkdaşlıq edə bilərsiniz.

LinkedIn: <https://www.linkedin.com/in/suleiman-hajizadeh-609732213/>

Github: <https://github.com/SuleimanHajizadeh>

Instagram: https://www.instagram.com/suleiman_hajizadeh/

Facebook: <https://www.facebook.com/suleiman.hajizadeh/>

Tiktok: <https://www.tiktok.com/@suleiman.hajizadeh>

Odnoklassnik: <https://ok.ru/profile/543832919542>

Telegram: @suleiman_hajizadeh

Whatsapp: +994705506907